Rapport Projet RL - TP2 AI Driver Unity (PPO)

Ajax DESHAYES--HUET

Introduction

Contexte

Ce TP2 porte sur l'entrainement d'un agent de conduite autonome dans Unity avec ML-Agents, en utilisant l'algorithme PPO. L'agent doit apprendre a suivre la piste de la scene track1 de facon fiable, avec peu de crashes, tout en conservant une progression stable pendant l'entrainement.

Objectifs

Ce rapport a pour objectifs de:

1. presenter la configuration de depart et les hyperparametres modifies,
2. comparer les resultats de trois experiences (E1, E2, E3),
3. analyser le compromis entre performance, stabilite et robustesse en inference,
4. justifier la configuration finale retenue.

Methodologie

Parametres modifiables

- Batch size.
- Buffer size.
- Learning rate.
- Epsilon.
- Beta.
- Lambda.

- Num epoch.
- Gamma.

Logique generale du rapport

Le rapport suit une demarche iterative: chaque experience sert a observer un comportement, identifier une limite, puis ajuster les parametres.
Les resultats de chaque run orientent directement l'objectif de l'experience suivante.

Experiences

> Consigne: faire 3 experiences maximum, pas besoin d'aller trop loin.

Tableau rapide

Experience	Batch size	lr	Epsilon	Beta	Lambda	Num epoch	Attente principale
E1	512	3e-4	0.2	0.005	0.95	3	Baseline
E2	1024	1.5e-4	0.15	0.003	0.95	3	Reward finale plus elevee mais moins stable
E3	768	2.2e-4	0.17	0.004	0.95	3	Compromis stabilite-rapidite: apprentissage rapide + inference robuste

Structure courte pour chaque experience

Experience E1

- **Choix des parametres**: batch size 512, learning rate 3e-4, epsilon 0.2, beta 0.005, lambda 0.95, num epoch 3.
- **Ce qu'on teste**: la baseline PPO sur track1.
- **Resultats observes**:

- Run lance avec `--run-id=Experience1` .

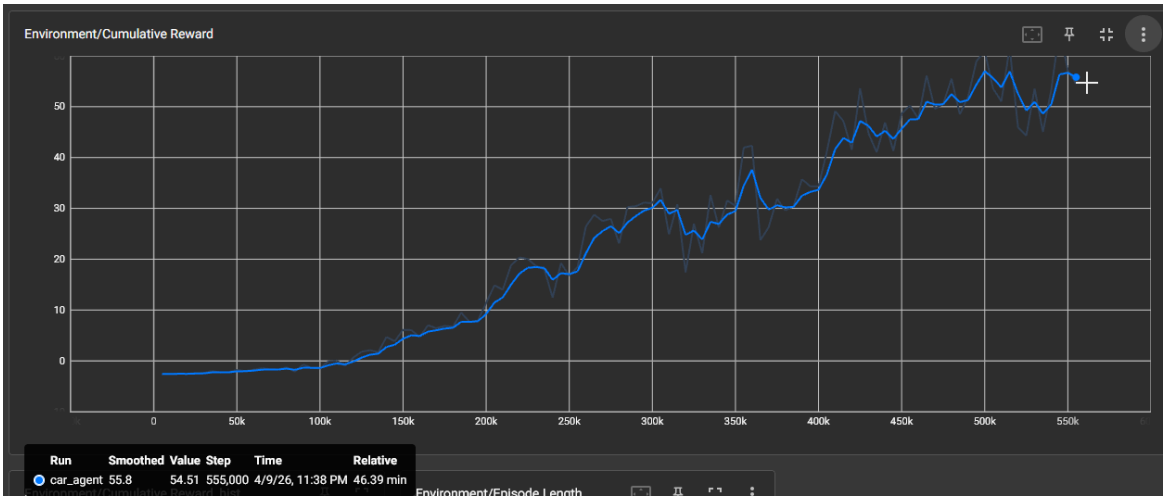

- La courbe `Environment/Cumulative Reward` monte globalement tout le long du run. - D'apres l'export JSON, la valeur passe d'environ `-2.57` au debut a un pic proche de `65.22` (step `545000`), puis termine vers `54.51` (step `555000`) apres un dip suivi d'une remontee. -

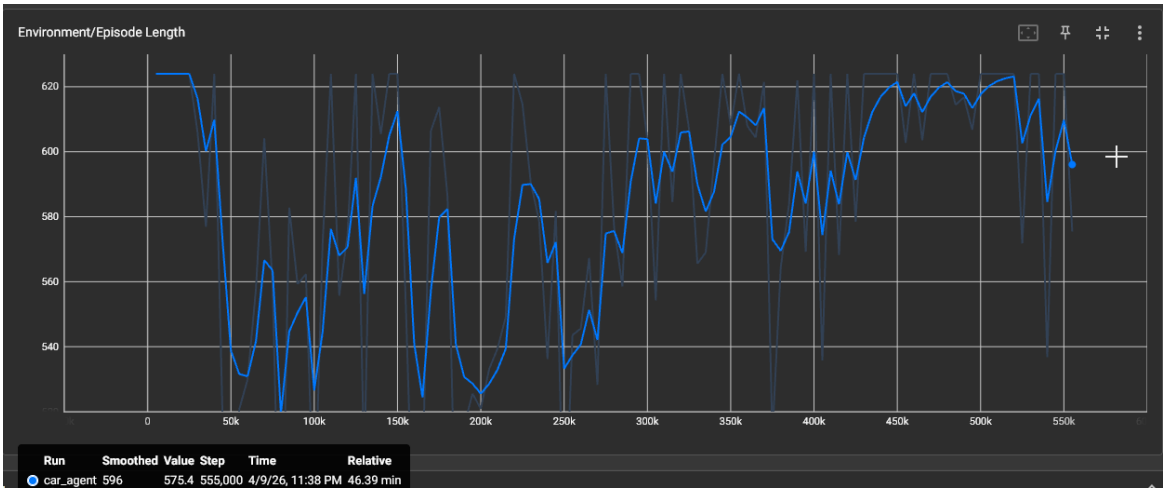

- `Environment/Episode Length` reste bruitee et souvent proche du plafond (`624`), avec quelques baisses ponctuelles (par exemple autour de `453` au step `80000`).

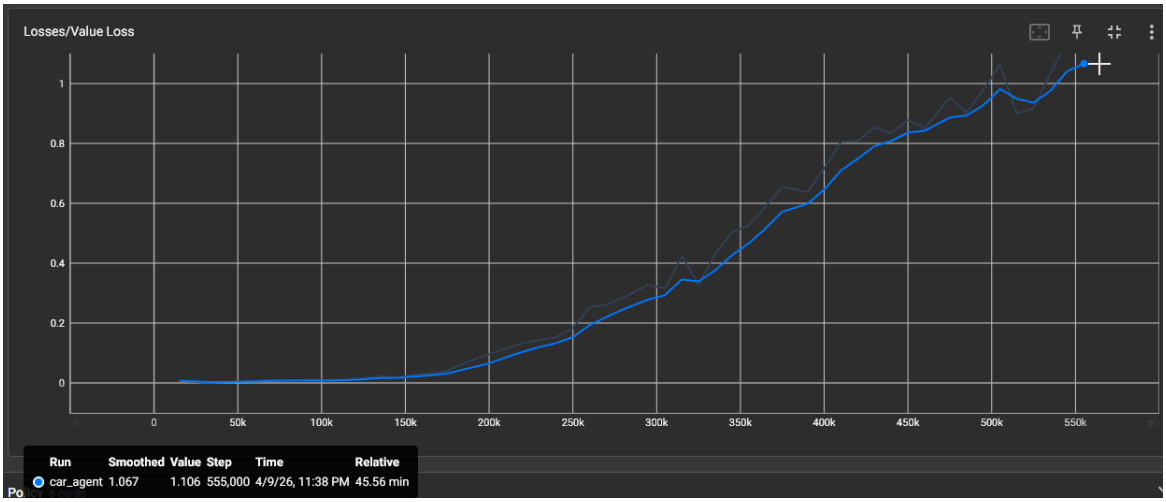

- `Losses/Policy Loss` oscille dans une plage assez stable, globalement entre `0.027` et `0.045`. - `Losses/Value Loss` augmente progressivement (d'environ `0.007` au debut jusqu'a ~`1.10` en fin de run), avec des fluctuations. - Test en inference apres entrainement: premier essai en echec (collision mur), deuxieme essai valide en `23.26 s` pour un tour. - **Interpretation**: la baseline apprend bien (reward en hausse nette), mais l'agent n'est pas encore regulier. La longueur d'episode souvent elevee et le premier crash en inference montrent qu'il y a encore un manque de robustesse. Le policy loss reste raisonnable, alors que le value loss qui grimpe suggere que le critic suit plus difficilement quand les retours deviennent plus eleves. - **Duree du run**: environ `46 minutes`. - **Critere d'arret**: arret manuel apres un dip qui a ete re-egalise, avec une courbe reward qui restait globalement ascendante.

Experience E2

- **Choix des parametres**:
  - `batch_size` : `512 -> 1024`
  - `learning_rate` : `3e-4 -> 1.5e-4`
  - `epsilon` (PPO clip): `0.2 -> 0.15`
  - `beta` (entropy): `0.005 -> 0.003`
  - `lambda` et `num_epoch` inchanges (`0.95` , `3`)
- **Ce qu'on teste**: conserver la progression reward de E1 avec une conduite plus reguliere (moins de collisions, meilleur temps de tour).
- **Pourquoi ces changements**:
  - `batch_size` augmente pour lisser les gradients,
  - `learning_rate` baisse pour des updates moins agressives,
  - `epsilon` diminue pour un clipping PPO plus prudent,
  - `beta` baisse legerement pour reduire l'aleatoire en fin d'apprentissage.
- **Resultats observes**:
  - Run lance avec `--run-id=Experience2` .

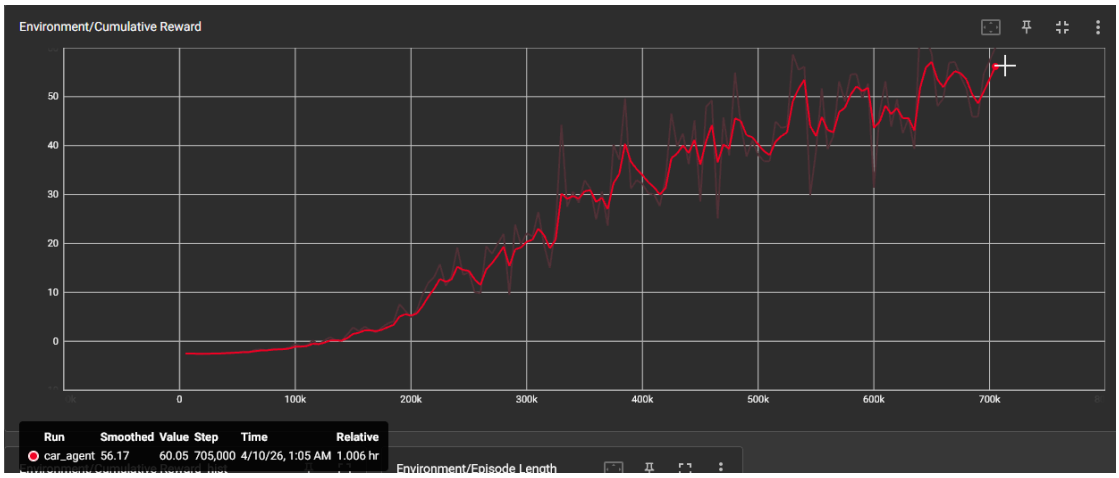

- Cumulative reward: -2.53 (debut) → 60.05 (step 705k, **plus eleve que E1 final!**)

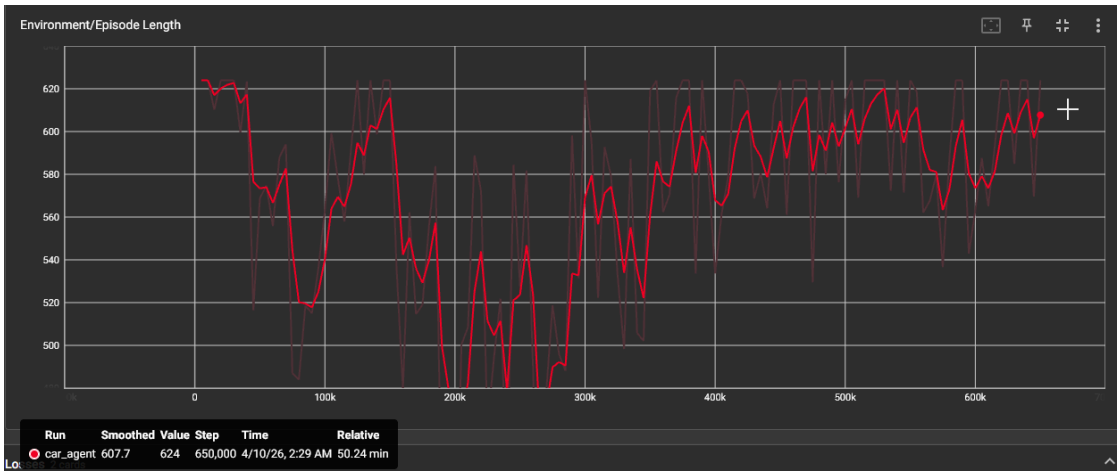

- Episode length: Similaire a E1, souvent proche du max 624 avec dips ponctuels.

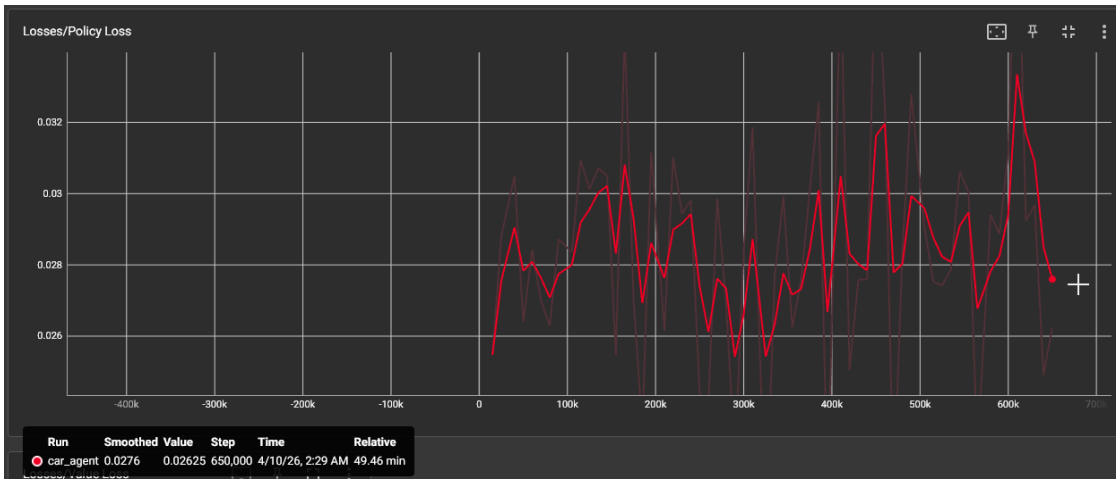

- Policy loss: Oscille entre 0.024-0.030 (stable, comparable a E1). - Value loss: Monte a 1.47 (legerement plus instabile que E1 qui atteignait max 1.10-1.25). - Tests en inference: plusieurs crashes et comportements erratiques (agent reste bloque apres avoir rate une reward, crash au debut d'autres parcours). Un essai a complete le tour en `20.18 sec` (plus rapide que E1).

- **Interpretation**: E2 atteint une reward finale plus elevee que E1 (+5.54), avec un tour reussi plus rapide (20.18 s vs 23.26 s). En contrepartie, la value loss monte davantage (1.47) et la robustesse d'inference diminue (crashes et comportements erratiques). Le compromis est donc une meilleure performance brute, mais une stabilite plus faible.

Experience E3

- **Choix des parametres**:
  - `batch_size` : `E1=512, E2=1024 → E3=768` (compromis intermédiaire)
  - `learning_rate` : `E1=3e-4, E2=1.5e-4 → E3=2.2e-4` (plus proche de E1 pour réduire instabilité)
  - `epsilon` (PPO clip): `E1=0.2, E2=0.15 → E3=0.17` (un peu plus de flexibilité que E2)
  - `beta` (entropy): `E1=0.005, E2=0.003 → E3=0.004` (milieu pour équilibrer exploration)
  - `lambda` et `num_epoch` inchanges (`0.95` , `3`)
- **Ce qu'on teste**: un compromis entre E1 et E2, avec une reward finale elevee et une inference plus robuste.

- **Pourquoi ces changements**:
  - `batch_size=768` pour un lissage intermediaire,
  - `learning_rate=2.2e-4` pour equilibrer vitesse et stabilite,
  - `epsilon=0.17` pour un clipping moins strict que E2,
  - `beta=0.004` pour equilibrer exploration et regularite de conduite.
- **Resultats observes**:
  - Run lance avec `--run-id=Experience3` .
  - Training duration: environ `50 minutes` pour atteindre 650k steps (`max_steps: 650000` arrêt automatique).

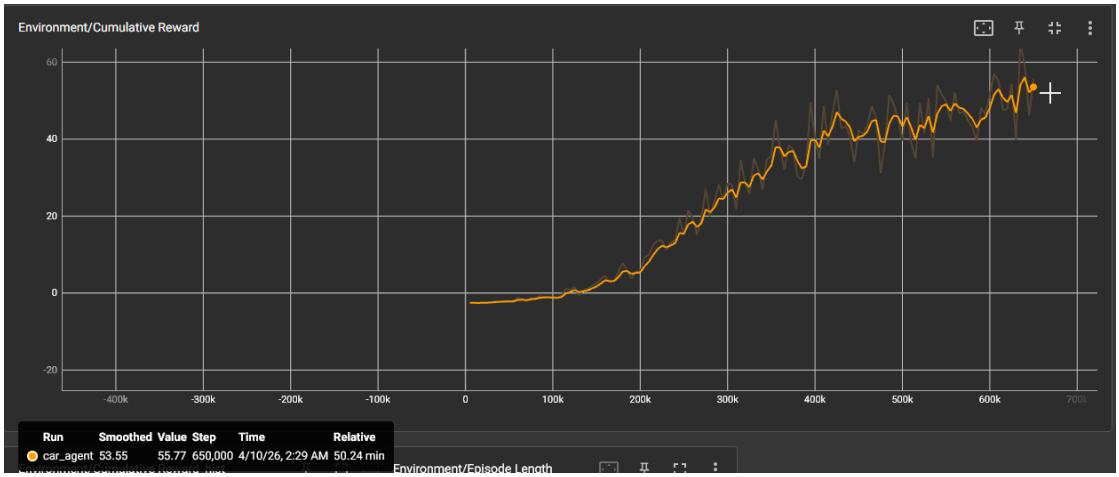

- Cumulative reward: -2.53 (debut) → 55.77 (step 650k)

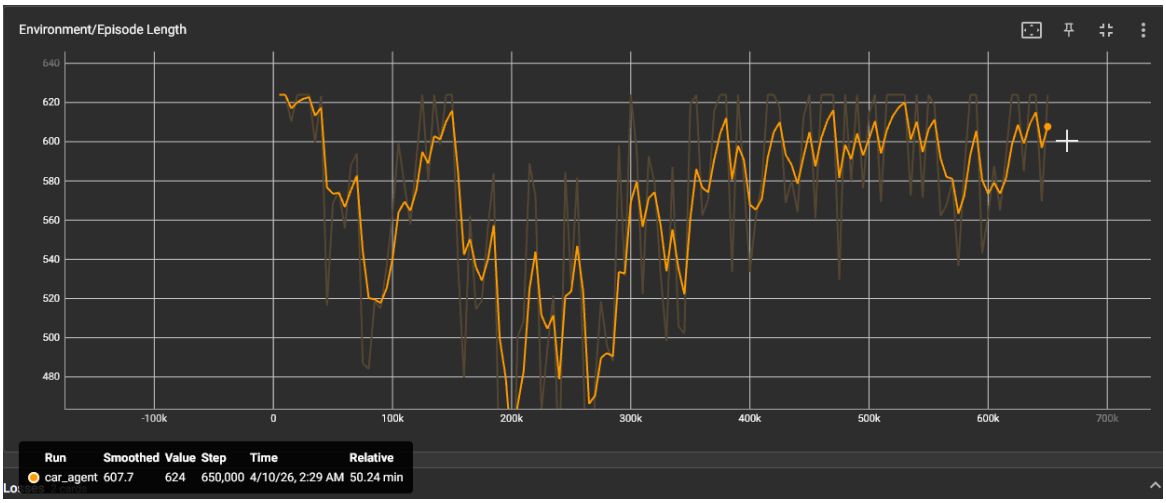

- Episode length: Similaire a E1/E2, souvent proche du max 624 avec dips ponctuels.

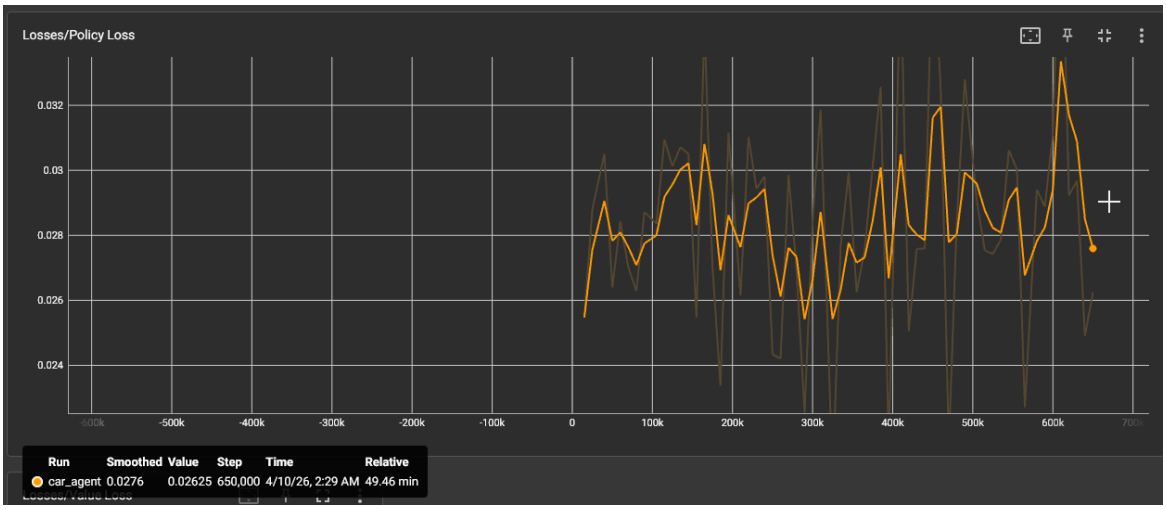

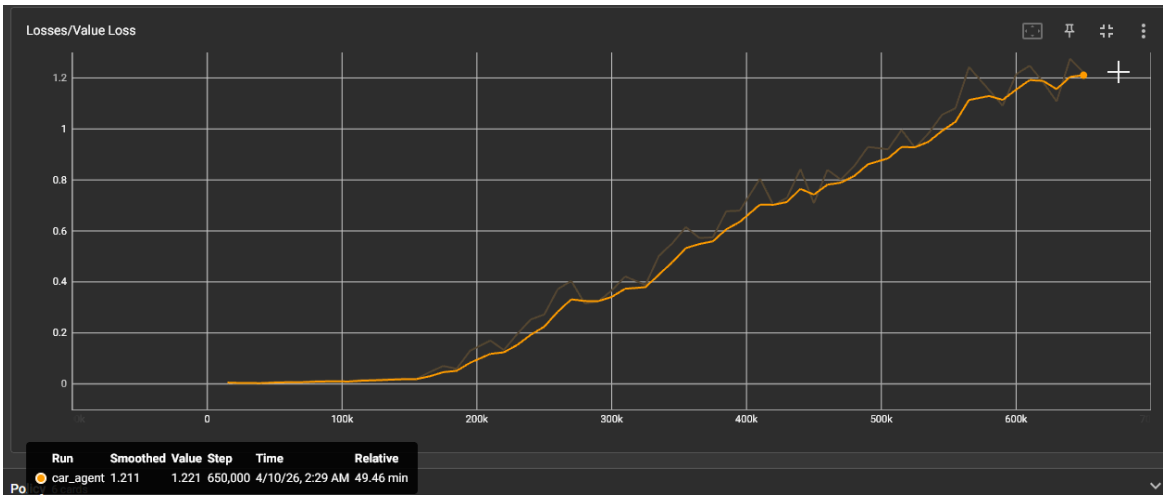

- Policy loss: Oscille entre 0.025-0.027 (tres stable, comparable a E1 et E2). - Value loss: Monte a 1.22 (entre E1 ~1.10-1.25 et E2 ~1.47) → meilleur que E2! - Tests en inference: agent observe plus stable, rare de rater une reward ou de crash dans les virages serre. Temps tour mesure: `20.91 sec`. - **Interpretation**: E3 atteint le compromis recherche: reward finale 55.77 (entre E1 et E2), value loss a 1.22 (meilleure que E2), et inference plus fiable que E2. Le temps de tour (20.91 s) reste proche de E2 tout en conservant une meilleure stabilite. Cette configuration offre donc le meilleur equilibre global performance/robustesse.

Resultats

Synthese courte: E1 est la baseline la plus stable, E2 atteint la meilleure reward finale mais avec plus d'instabilite, et E3 donne le meilleur compromis global entre performance, stabilite et inference.

Comparaison finale

Critere	E1	E2	E3
Reward finale	54.51	60.05	55.77
Value loss finale	1.10-1.25	1.47	1.22
Temps tour moyen (reussi)	23.26 s	20.18 s	20.91 s
Robustesse inference	Stable mais lente	Plus rapide mais moins fiable	Meilleur compromis

Analyse

Les resultats montrent un compromis net entre rapidite et stabilite: E2 maximise la reward, mais perd en robustesse d'inference. E3 fournit le meilleur equilibre avec une value loss mieux maitrisee et un comportement plus fiable; les limites restent le faible nombre de runs (1/config) et l'alea de l'environnement.

Conclusion

E3 est la configuration retenue pour le TP2: elle garde une reward finale elevee, une value loss mieux controlee que E2, et une robustesse en inference plus solide. Le point principal du projet est confirme: augmenter la vitesse d'apprentissage n'est utile que si la stabilite reste acceptable. Pour aller plus loin, une suite logique est d'appliquer un learning rate decay ou de prolonger legerement E3.